

Projet HealthConnect — Semaine 7 : Validation des Indicateurs Financiers, Optimisation du Dashboard et Note de Transmission Data Science

A. LE DATASET NETTOYE (Fichier CSV / Excel)

Le fichier nettoyé HealthConnect_Appointment_Data.csv a été exporté et déposé dans le répertoire partagé du projet / Google Drive à l'attention de l'équipe Data Science.

<https://drive.google.com/drive/folders/1TvcgmV9tokZDXpP0CMndvrM6MTDiMOAq?usp=sharing>

B. NOTE DE TRANSMISSION INTERDISCIPLINAIRE (HANDOVER NOTE)

De : Analyste Data & Investment Analytics (Track Data Analytics)

À : Équipe Data Science & Modélisation Prédictive

Projet : HealthConnect — Optimisation du Taux de No-Show & Recouvrement de Revenus

Date : Semaine 7 — Phase d'Audit & Cadre de Modélisation

Statut : Formellement validé post-Due Diligence

1. CONTEXTE & OBJECTIF STRATÉGIQUE

À l'issue de l'audit financier et de l'analyse décisionnelle menés en Semaine 6 et 7 sur Power BI, nous avons identifié un risque financier majeur :

- **Taux d'absentéisme global (No-Show) : 48,46 %** (3 877 rendez-vous manqués sur 8 000).
- **Perte financière directe : 73 M FCFA** de revenus perdus (Coût des créneaux inexploités : 36 M FCFA).
- **Opportunité financière :** Un gain récupérable estimé à **11 M FCFA** sous l'hypothèse conservatrice d'une réduction de **15 %** des absences.

L'objectif de la transmission au track **Data Science** est d'évoluer d'un constat **descriptif/financier (Power BI)** vers une **capacité prédictive (Machine Learning)** permettant d'anticiper le comportement du patient lors de la prise de RDV.

2. DÉFINITION DE LA VARIABLE CIBLE (TARGET)

L'équipe Data Science est invitée à construire un modèle de classification supervisée basé sur la variable cible suivante :

- **Variable Cible (Target) :** status
 - **Encodage binaire recommandé :** 1 = No-Show (Absence) | 0 = Show (Présence).
 - **Déséquilibre de classe :** Léger déséquilibre (~48,5 % No-Show vs ~51,5 % Show). Aucun sur-échantillonnage lourd (SMOTE) n'est nécessaire a priori, mais une métrique de scoring adaptée (ex: **ROC-AUC** et **Precision-Recall / F1-Score**) doit être privilégiée par rapport à la simple Accuracy.

3. SELECTION DES VARIABLES CRITIQUES (TOP 5 FEATURES AUDITÉES)

L'audit de Due Diligence analytique a permis de filtrer et d'isoler **5 variables prédictives majeures** ayant un impact direct sur la création de valeur et la perte financière. L'équipe Data Science doit obligatoirement les intégrer dans l'évaluation de l'importance des variables (*Feature Importance*) :

Variable (Feature)	Type	Constat Analytics & Biais Identifié	Règle Métier Découverte
previous_no_shows	Numérique (Discret)	Facteur #1 de récidence. Risque d'absence exponentiel avec l'historique.	Taux de No-Show proche de 100 % dès ≥ 3 absences historiques.
booking_lead_days	Numérique (Discret)	Forte dégradation de l'engagement à mesure que le délai s'allonge.	Taux d'absence de 24,84 % ($\leq 3j$) contre 54,36 % ($> 14j$).
distance_to_clinic_km	Numérique (Continu)	Seuil de renoncement géographique mesuré au-delà de 15 km.	Point culminant d'absentéisme à 51,91 % sur le segment +15 km.
reminder_channel	Catégorielle	Écart d'efficacité net entre l'absence de rappel/SMS et les canaux interactifs.	Axe prioritaire pour le déclenchement de la solution WhatsApp.
age_group	Catégorielle	Variabilité démographique du taux de présence à contrôler.	Variable de contrôle pour corriger les biais générationnels.

4. SEUIL MÉTIER & CONTRAINTES OPÉRATIONNELLES (BUSINESS THRESHOLD)

Afin que le modèle prédictif génère une valeur financière directe, il devra restituer un **Score de Probabilité d'Absence** ($P(\text{No-Show}) \in [0,1]$).

- **Seuil d'Activation Déclenché** : $P(\text{No-Show}) \geq 0,70$ (Patients à Haut Risque).
- **Justification Financière** : L'envoi automatisé de rappels interactifs sur l'API WhatsApp génère un coût marginal payant pour la clinique. Le modèle Data Science doit cibler **uniquement** le segment des patients à haut risque ($> 70\%$) afin de maximiser le ROI de la campagne sans gaspiller de budget de communication sur les patients déjà engagés.

5. LIVRABLES ENTRANTS / SORTANTS (FLUX INTERDISCIPLINAIRE)

A. Livrables transmis par Data Analytics à Data Science (Entrants) :

1. **Dataset Source Audité** : HealthConnect_Appointment_Data.csv (Données nettoyées et cohérentes).
2. **Cadrage des variables** : Spécification de la Target et des 5 Features principales ci-dessus.

B. Livrables attendus de la Data Science pour la Semaine 8 (Sortants) :

1. **Table enrichie** : Fichier de retour incluant la colonne prédictive Score_Risque_NoShow (probabilité continue entre 0 et 1) et la classe prédictive Prediction_NoShow (0 ou 1).
2. **Graphe de Feature Importance** : Confirmation par l'algorithme (ex: Random Forest, XGBoost) de la hiérarchie des 5 variables identifiées.

C. LES RESULTATS D'AUDIT

1. DÉCOUVERTES FINANCIÈRES CLÉS (FINANCIAL BASELINE)

- Volume d'analyse : 8 000 consultations auditées.
- Taux d'absentéisme global (No-Show Rate) : 48,46 % (3 877 rendez-vous non honorés).
- Impact financier brut : 73 M FCFA de chiffre d'affaires perdu (perte directe des créneaux non réattribués).
- Coût direct des créneaux vacants : 36 M FCFA d'immobilisation des ressources médicales.
- Potentiel de récupération simulé : 11 M FCFA récupérables sous l'hypothèse conservatrice d'une réduction de 15 % du taux de No-Show grâce au ciblage prédictif.

2. HIÉRARCHIE ET COMPORTEMENT DES VARIABLES CRITIQUES

L'audit approfondi et les tests de sensibilité croisés sur Power BI ont permis d'établir le comportement exact des 5 variables que le modèle de Machine Learning devra exploiter :

◆ 1. Historique d'absences (previous_no_shows) — *Poids prédictif estimé : Ultra-Élevé*

- Constat : C'est le prédicteur comportemental le plus fort du dataset.
- Règle découverte : Le risque de récurrence suit une courbe fortement exponentielle.
 - Patients à 0 absence passée : Taux de No-Show modéré.
 - Patients à ≥ 2 absences passées : Taux de No-Show $> 75\%$.

- Patients à ≥ 3 absences passées : Taux de No-Show frôlant les 100 %.

◆ **2. Délais de réservation (booking_lead_days) — Poids prédictif estimé : Élevé**

- Constat : Plus le délai entre la prise de RDV et le jour de la consultation est long, plus l'engagement du patient s'effrite.
- Comportement par tranche :
 - 0 à 3 jours : Taux de No-Show bas de 24,84 %.
 - 4 à 7 jours : Taux de No-Show de 30,75 %.
 - 8 à 14 jours : Taux de No-Show de 33,55 %.
 - > 14 jours : Point de rupture majeur avec un taux d'absence qui explose à 54,36 %.

◆ **3. Éloignement géographique (distance_to_clinic_km) — Poids prédictif estimé : Moyen à Élevé**

- Constat : La distance crée une friction logistique directe.
- Seuil critique : Les taux d'absences restent stables jusqu'à 15 km (~46% à 48%), mais connaissent un pic à 51,91 % dès que le patient réside à plus de 15 km de la clinique.

◆ **4. Canal de rappel (reminder_channel) — Poids prédictif estimé : Élevé (Lever d'action)**

- Constat : L'absence de rappel (None) ou l'envoi de simples SMS passifs affichent un taux d'échec élevé.
- Opportunité : Les canaux interactifs (ex: WhatsApp) réduisent l'oubli et permettent une annulation précoce réinjectant le créneau dans la liste d'attente.

◆ **5. Tranche d'âge (age_group) — Variable de contrôle**

- Constat : Permet de segmenter la réceptivité aux canaux de rappel (les tranches jeunes répondent mieux à WhatsApp, tandis que les seniors nécessitent parfois d'autres canaux).

3. CONSIGNES DE MODÉLISATION POUR LA DATA SCIENCE

1. Focus sur la combinaison à ultra-haut risque :

Les tests démontrent que la combinaison simultanée booking_lead_days > 14 AND previous_no_shows >= 2 garantit une probabilité d'absence supérieure à 80 %. Le modèle devra être capable de capturer cet effet d'interaction.

2. Sortie attendue pour la Semaine 8 :

Générer un score de probabilité individuel (Score_Risque_NoShow) qui sera réintégré dans le tableau de bord Power BI afin de filtrer et déclencher les campagnes de rappels WhatsApp ciblées pour tout risque calculé $\geq 70\%$.